

Relatório Técnico: Database - 1985 Auto Imports (19)

Professor: Rilder de Sousa Pires

Equipe G: André Lima Vieira - 2214650, Leonardo Farias Macieira - 2110937, Samuel Rodrigues Maia Nunes - 2412877, Ravi Freitas Gondim Viana - 2316154, José Fernando B Carvalho de Oliveira - 2412833

Relatório Técnico: Previsão de Preços de Veículos

1. Introdução

Descrição do problema

A indústria automotiva é um mercado altamente competitivo e dinâmico, onde a precificação adequada dos veículos é fundamental para o sucesso comercial. O preço de um automóvel é influenciado por uma vasta gama de características técnicas, de design e de desempenho. O problema abordado neste trabalho consiste em compreender como esses diversos atributos impactam o valor final de um veículo e, a partir disso, desenvolver um modelo preditivo capaz de estimar o preço de carros com base em suas especificações.

Objetivo do trabalho

O objetivo principal deste trabalho é desenvolver e avaliar modelos de Aprendizado de Máquina para a previsão de preços de veículos. Busca-se identificar quais características técnicas são os melhores preditores de preço, aplicar técnicas adequadas de pré-processamento para garantir a qualidade dos dados e comparar o desempenho de diferentes algoritmos preditivos, assegurando a validade e a robustez dos resultados obtidos.

2. Dataset

Fonte dos dados

Os dados utilizados neste estudo foram extraídos do **1985 Auto Imports Dataset**, disponibilizado publicamente no UCI Machine Learning Repository [1]. Este conjunto de dados é amplamente reconhecido na comunidade acadêmica para estudos de regressão e análise exploratória.

Descrição das principais variáveis

O dataset original é composto por 205 registros (linhas) e 26 atributos (colunas). A variável alvo do estudo é o `price` (preço do veículo em dólares), que é uma variável contínua. Os valores ausentes no arquivo original são representados pelo caractere `?`.

A Tabela 1 apresenta as principais variáveis utilizadas na modelagem:

Variável	Tipo	Descrição
price	Contínua (Alvo)	Preço do veículo em dólares
make	Categórica	Fabricante (audi, bmw, toyota, etc.)
engine-size	Contínua	Tamanho do motor em cm ³
horsepower	Contínua	Potência em cavalos de força
curb-weight	Contínua	Peso sem carga em libras
city-mpg	Contínua	Consumo na cidade (milhas/galão)
highway-mpg	Contínua	Consumo na estrada (milhas/galão)
body-style	Categórica	Estilo da carroceria (sedan, hatchback, etc.)
fuel-type	Categórica	Tipo de combustível (gas, diesel)
num-of-cylinders	Categórica	Número de cilindros
aspiration	Categórica	Aspiração (std, turbo)

Tipo do problema

Trata-se de um problema de **Regressão**, uma vez que o objetivo é prever um valor numérico contínuo (o preço do veículo), em oposição a classificar instâncias em categorias discretas.

3. Análise e Pré-processamento

Principais análises exploratórias

A análise exploratória inicial revelou padrões importantes na distribuição dos dados. A distribuição da variável alvo `price` apresentou-se positivamente assimétrica (skewed right), indicando que a grande maioria dos veículos no dataset são modelos populares de

menor valor, enquanto uma pequena parcela é composta por carros de luxo com preços significativamente mais elevados.

A análise bivariada, suportada pela Matriz de Correlação, revelou relações lineares fortes entre as variáveis. Observou-se uma correlação forte e positiva entre o preço (`price`) e as variáveis de desempenho e tamanho, como `engine-size` e `horsepower`. Por outro lado, identificou-se uma correlação negativa entre o preço e as variáveis de eficiência de combustível (`city-mpg` e `highway-mpg`), evidenciando o padrão esperado de que carros mais potentes e caros tendem a consumir mais combustível.




Figura 1 — Matriz de Correlação das variáveis numéricas do dataset Auto Imports.

Tratamentos realizados nos dados

Tratamento de valores nulos e inconsistências

O primeiro passo do tratamento consistiu na remoção de inconsistências críticas. Linhas que apresentavam valores nulos na variável alvo (`price`) foram sumariamente removidas, pois a ausência do rótulo impossibilita o treinamento supervisionado.

Para as demais variáveis, a imputação de valores nulos foi realizada de forma diferenciada:

- * **Variáveis numéricas:** Os valores ausentes foram preenchidos com a mediana da respectiva coluna, uma medida de tendência central robusta a valores extremos.
- * **Variáveis categóricas:** Os valores ausentes foram preenchidos com a moda (o valor mais frequente

da categoria).

Tratamento de outliers

A presença de outliers, especialmente na variável alvo, pode distorcer significativamente o ajuste de modelos de regressão. Para mitigar esse efeito, aplicou-se o método do Intervalo Interquartil (IQR) na variável `price`. O limite superior foi definido pela fórmula $Q3 + 1.5 \times IQR$. Veículos com preços acima desse limite foram removidos do conjunto de dados. Essa decisão técnica justifica-se pelo fato de que esses modelos de alto luxo representam um nicho de mercado distinto, e sua manutenção distorceria as previsões para o público-alvo geral do modelo.

Transformações aplicadas

Separação dos dados (Treino/Teste) e Prevenção de Data Leakage

Para garantir uma avaliação honesta e prevenir o vazamento de dados (Data Leakage), a separação do conjunto de dados em subconjuntos de treinamento (80%) e teste (20%) foi realizada **antes** de qualquer transformação ou imputação. Isso assegura que as estatísticas utilizadas para imputação e padronização sejam calculadas exclusivamente com base nos dados de treino, simulando um cenário real de predição.

Codificação e Normalização

As variáveis categóricas foram transformadas utilizando a técnica de *One-Hot Encoding*, que converte cada categoria em uma nova variável binária, permitindo que os algoritmos processem essas informações sem assumir uma ordem hierárquica inexistente.

As variáveis numéricas foram submetidas a um processo de padronização utilizando o *StandardScaler*, que transforma os dados para que tenham média 0 e desvio padrão 1. Essa etapa é crucial para modelos sensíveis à escala das variáveis, como a Regressão Linear.

Todo o fluxo de pré-processamento foi organizado utilizando *Pipelines* da biblioteca Scikit-Learn [2], garantindo a integridade das transformações e facilitando a reprodutibilidade do experimento.

4. Modelagem

Modelos utilizados

Para este estudo, foram selecionados dois algoritmos com características distintas para permitir uma comparação abrangente:

1. **Regressão Linear Múltipla (Baseline):** Um modelo clássico, paramétrico e altamente interpretável. Ele assume a existência de uma relação linear entre as variáveis preditoras (features) e a variável alvo. Serve como uma excelente linha de base (baseline) para avaliar se modelos mais complexos justificam seu custo computacional.
2. **Random Forest Regressor:** Um modelo de *ensemble* baseado em múltiplas árvores de decisão. É um algoritmo não-paramétrico capaz de capturar relações não-lineares complexas e interações entre as variáveis sem a necessidade de transformações manuais prévias.

Estratégia de treinamento

Os modelos foram treinados utilizando o subconjunto de treinamento (80% dos dados). O modelo Random Forest foi instanciado com o hiperparâmetro `n_estimators=100` (cem árvores no comitê) e `random_state=42` para garantir a reprodutibilidade dos resultados. O pipeline de pré-processamento foi integrado ao treinamento, assegurando que os dados de teste passassem exatamente pelas mesmas transformações aprendidas durante o ajuste do modelo.

5. Resultados

Métricas utilizadas

A avaliação do desempenho dos modelos foi realizada com base em três métricas principais, adequadas para problemas de regressão:

- **RMSE (Raiz do Erro Quadrático Médio):** Penaliza erros maiores de forma mais severa. Sua principal vantagem é ser interpretável na mesma unidade da variável alvo (dólares).
- **MAE (Erro Absoluto Médio):** Representa a média das diferenças absolutas entre as previsões e os valores reais. É uma métrica mais robusta à presença de eventuais outliers remanescentes.
- **R² (Coeficiente de Determinação):** Indica a proporção da variância na variável dependente que é previsível a partir das variáveis independentes. Varia de 0 a 1, sendo que valores mais próximos de 1.0 indicam um melhor ajuste do modelo.

Comparação entre modelos

A avaliação no conjunto de teste demonstrou que o modelo Random Forest superou a Regressão Linear Múltipla em todas as métricas analisadas. O modelo de *ensemble* apresentou menores valores de erro (RMSE e MAE) e um coeficiente de determinação (R²) superior, indicando uma capacidade preditiva mais acurada.




Figura 2 — Preço Real vs. Preço Previsto pelo modelo Random Forest Regressor.

Discussão dos resultados

A superioridade do Random Forest justifica-se pela natureza do problema. O preço de veículos não possui uma relação puramente linear com suas características. A combinação de atributos categóricos (como a marca) e características físicas (como o tipo de carroceria) cria “saltos” de preço e interações complexas que as árvores de decisão conseguem capturar de forma muito mais eficaz do que um modelo linear estrito.

Em relação ao *overfitting* (sobreajuste), a adoção de um pipeline rigoroso com separação estrita entre treino e teste garantiu uma avaliação honesta do poder de generalização. O modelo Random Forest não apresentou sinais de *overfitting* severo, mantendo um desempenho consistente nos dados não vistos.

6. Conclusão

Principais aprendizados

O desenvolvimento deste trabalho permitiu concluir que as características técnicas de um veículo são, de fato, ótimos preditores para o seu preço de mercado. A análise exploratória confirmou expectativas intuitivas, como a correlação entre potência, consumo e valor. Além disso, constatou-se que o tratamento adequado de outliers foi uma etapa decisiva para estabilizar o treinamento e melhorar a confiabilidade das previsões.

Limitações e possíveis melhorias

Apesar dos bons resultados, o estudo apresenta limitações inerentes aos dados. O dataset utilizado é relativamente pequeno, contendo apenas algumas centenas de instâncias. Isso limita a capacidade do modelo de aprender padrões mais sutis. Outra limitação observada foi a esparsidade gerada pelo *One-Hot Encoding* em variáveis categóricas com muitos níveis, especialmente para marcas de veículos com poucos registros no dataset.

Para trabalhos futuros, sugere-se a implementação de técnicas de Validação Cruzada (*Cross-Validation*) para uma estimativa de erro mais robusta. Adicionalmente, a aplicação de métodos de otimização de hiperparâmetros, como o *GridSearchCV*, poderia refinar ainda mais o desempenho do modelo Random Forest.

7. Referências

[1] UCI Machine Learning Repository. “Automobile Data Set”. Disponível em: <https://archive.ics.uci.edu/ml/datasets/automobile>. [2] Scikit-Learn Developers. “Scikit-Learn Documentation”. Disponível em: <https://scikit-learn.org/stable/>. [3] Pandas Developers. “Pandas Documentation”. Disponível em: <https://pandas.pydata.org/docs/>. [4] Matplotlib

Developers. “Matplotlib Documentation”. Disponível em: <https://matplotlib.org/stable/contents.html>.